Prosjekt 1: COMPAS

HON2200

Amélie Wessel
Eman Ghazniwal
Ådne Rolstad

Universitet i Oslo
April 2026
Gruppe 12

Abstract

I denne rapporten utfører vi en algoritmerevisjon av COMPAS, et risikovurderingsverktøy brukt i det amerikanske rettsvesenet. Ved hjelp av ProPublicas datasett analyserer vi feilklassifiseringsrater, etniske skjevheter og modellens prediktive egenskaper. Analysen viser at COMPAS har en betydelig høyere falsk positiv-rate for svarte individer (0.423) enn for hvite (0.220), og at svarte tiltalte er omtrent 45% mer sannsynlige til å få høy risikoscore selv etter kontroll for alder, kjønn og kriminell historikk. Vi trener en Random Forest modell uten etnisitet som input, og oppnådde marginalt høyere nøyaktighet enn COMPAS. Likevel forble gruppeforskjellene, noe som indikerer at variabler som antall tidligere lovbrudd er strukturelt korrelert med etnisitet, og dermed fungerer som proxy-variabler for dette. Vi diskuterer hva rettferdighet i algoritmer innebærer, forskjellen mellom Northpointes og ProPublicas forståels av rettferdige algoritmer, og hvordan man kan konstruere rettferdige algoritmer i et urettferdig samfunn.

Innhold

1 Introduksjon **2**

2 Metode **2**
2.1 Data 2
2.2 Statistisk analyse 2
2.3 Logistisk regresjon 2
2.4 Random Forest 2

3 Dataanalyse **2**
3.1 Deskriptiv analyse 2
3.2 Feilklassifiseringsrater 3
3.3 Logistisk regresjon og etnisk skjevhet 3
3.4 Random Forest 4

4 Diskusjon **5**
4.1 Sammenheng med Bayes' setning 5
4.2 Hvorfor bruke algoritmer i rettsvesenet? 6
4.2.1 Bakgrunn 6
4.2.2 Effektivitet 6
4.2.3 Skjevheter 6
4.3 Hvordan kan en rettferdig algoritme se ut? 6
4.3.1 «Rettferdighet» som et designvalg 6
4.3.2 Statistisk diskriminering 6
4.3.3 Et retrospektivt syn på rettferdighet i algoritmer 7
4.3.4 Algoritmer mangler intensjon om å diskriminere 7
4.4 Å skape en rettferdig modell i et urettferdig samfunn 7
4.4.1 Like muligheter vs. like utfall 8
4.5 Tiltak for å korrigere urettferdige modeller 8
4.5.1 «Unware»-tilnærming . . 9
4.5.2 «Aware»-tilnærming . . . 9
4.6 Northpointe vs. ProPublica . . 9

5 Konklusjon **10**

1 Introduksjon

I denne oppgaven undersøker vi om det er rettferdig at dommere bruker COMPAS-scorer i vurderingen av straffeutmåling. Kunstig intelligens-baserte "black box"-modeller som COMPAS har fått en stadig større rolle i rettssystemet. Opprinnelig var hensikten å bidra til mer rettferdig og individuell behandling, men forskning tyder på at slike systemer kan forsterke allerede eksisterende skjevheter i samfunnet.

I kapittel 2 presenterer vi datasettet vi har brukt, samt en logistisk regresjonsmodell inspirert av ProPublicas studie. I tillegg har vi trent en random forest-modell for å kunne sammenligne resultatene fra ulike metodiske tilnærminger.

I kapittel 3 gjennomfører vi en deskriptiv analyse av dataene, inkludert figurer som illustrerer potensielle etiske skjevheter i COMPAS-systemet. I diskusjonsdelen i kapittel 4 tar vi opp mer normative spørsmål, som hva som kjennetegner en rettferdig modell—bør man prioritere like muligheter eller like utfall? Videre diskuterer vi hvordan algoritmer kan gjøres mer rettferdige, blant annet gjennom "aware" og "unaware" tilnærminger.

Avslutningsvis sammenligner vi våre funn med analysene til Northpointe og ProPublica.

2 Metode

2.1 Data

Datasettet som er brukt i analysen er `compas-scores-two-years.csv`, hentet fra ProPublica (2016). For å følge ProPublicas metodikk fjernet vi rader der tidsforskjellen mellom arrestasjon og COMPAS-vurdering var større enn 30 dager. Variablene som ble brukt er alder (`age_cat`), etnisitet (`race`), kjønn (`sex`), antall tidligere lovbrudd (`priors_count`), alvorlighetsgrad på lovbruddet (`c_charge_degree`), faktisk gjentakelse innen to år (`two_year_recid`), og COMPAS-score (`score_text`, kategorisert som «Low», «Medium» eller «High»). Dataene ble analysert med `Pandas` og `Matplotlib` i `Python`.

2.2 Statistisk analyse

Vi antok at COMPAS predikerer gjentakelse for individer med `score_text` lik «Medium» eller «High», og beregnet ratene av falske positive (FPR), falske negative (FNR), sanne positive (TPR), sanne negative (TNR) og positiv prediktiv verdi (PPV) for ulike grupperinger av individer.

2.3 Logistisk regresjon

Vi trente en logistisk regresjonsmodell med COMPAS-score som responsvariabel for å undersøke hvilke forklaringsvariabler som driver algoritmens prediksjoner. Vi brukte samme kovariatmatrise som i ProPublicas studie, med one-hot-encoding av kategoriske variabler.

2.4 Random Forest

Vi trente en Random Forest-modell (RF) for å predikere faktisk gjentakelse direkte, uten etnisitet som input, og sammenliknet treffsikkerhet og feilklassifiseringsrater med COMPAS. Dataene ble delt i trenings- og testsett med en fast seed på 2704, og antall trær ble valgt ved å evaluere accuracy score for ulike antall svake lærere.

3 Dataanalyse

3.1 Deskriptiv analyse

Den observerte gjentakelsesraten varierer mellom grupper. Menn gjentok kriminalitet oftere enn kvinner, og svarte individer oftere enn hvite. COMPAS overpredikerte gjentakelsesraten for svarte og kvinner, mens algoritmen underpredikerte for hvite, som vist i tabell 1.

Fordelingen av risikoskårer viser tydelige gruppeforskjeller mellom etnisiteter og kjønn, som vist i figurene 1 og 2. Hvite individer fikk score «Low» i 66,9% av tilfellene, mot 42,4% for svarte. Svarte fikk «Medium» eller «High» i til sammen 57,6% av tilfellene, mot 33,1%

Gruppe	Observert rate	Predikert rate
Kvinner	35.1%	40.5%
Menn	47.9%	45.5%
Svarte	52.3%	57.6%
Hvite	39.1%	33.1%

Tabell 1: Observert og predikert gjentakelsesrate per gruppe

for hvite. Kjønnsforskjellene er mindre, men menn fikk «High» oftere enn kvinner (19,9% mot 12,9%).

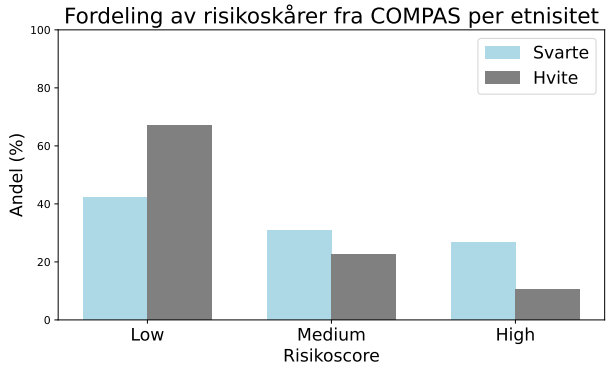

Figur 1: Fordeling av risikoscores for mørke og hvite. Hvite individer får oftere score «Low» enn mørke, mørke individer får score «Medium» og «High» oftere enn hvite.

Figurene 3, 4 og 5 viser sammenhengen mellom faktisk gjentakelse og risikoscore. For hele datasettet fikk 69,7% av ikke-gjentakerne «Low», mot 38,3% av gjentakerne. Denne forskjellen er større for hvite enn for svarte: blant hvite ikke-gjentakere fikk 78,0% «Low», mot 57,7% for svarte ikke-gjentakere. Dette tyder på at algoritmen skiller tydeligere mellom gjentakere og ikke-gjentakere for hvite enn for svarte.

3.2 Feilklassifiseringsrater

Tabell 2 viser feilklassifiseringsratene for COMPAS per gruppe. Den falske positive raten (FPR) er betydelig høyere for svarte (0,423) enn for hvite (0,220), noe som betyr at svarte individer som ikke gjentok kriminalitet langt oftere ble feilaktig klassifisert som høy risiko. Den falske negative raten (FNR) er derimot lavere for svarte (0,285) enn for hvite (0,496),

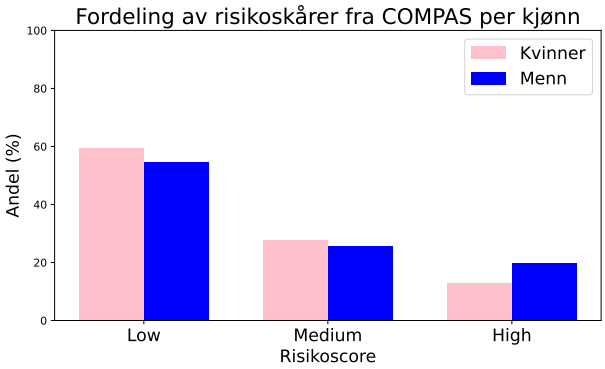

Figur 2: Fordeling av risikoskårer fra COMPAS-algoritmen for kvinner og menn. Fordelingen er ganske lik for kjønnene, men menn får predikert risiko «High» oftere enn kvinner.

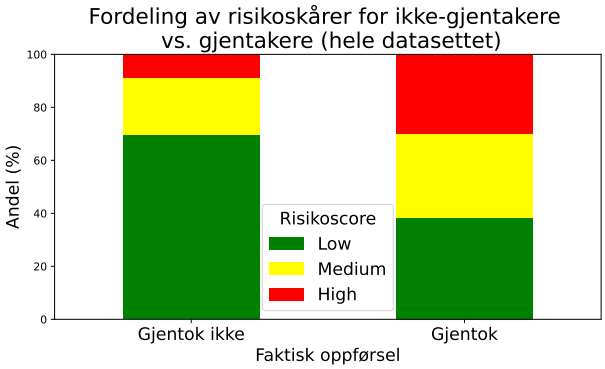

Figur 3: Sammenlikning av risikoskårer for individer som ikke gjentok straffbare handlinger og individer som gjentok, for hele datasettet. Ikke-gjentakere får mildere risikoskårer enn gjentakere.

noe som innebærer at COMPAS overser faktiske gjentakere oftere blant hvite enn blant svarte.

Den positive prediktive verdien (PPV) er 0,630 for hele datasettet, og varierer fra 0,517 for kvinner til 0,654 for menn. For hvite er PPV 0,595 og for svarte 0,650, noe som indikerer at kalibreringen er relativt lik på tvers av etnisitet. Sammenhengen mellom PPV, TPR og gjentakelsesrater diskuteres nærmere i avsnitt 4.1.

3.3 Logistisk regresjon og etnisk skjevhet

For å undersøke hvilke variabler som driver COMPAS sine prediksjoner, trente vi en logis-

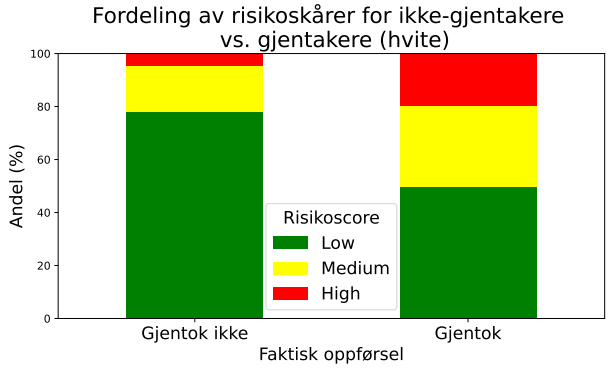

Figur 4: Sammenlikning av risikoskårer for hvite ikke-gjentakere og gjentakere. Ikke-gjentakere får mildere risikoskårer enn gjentakere.

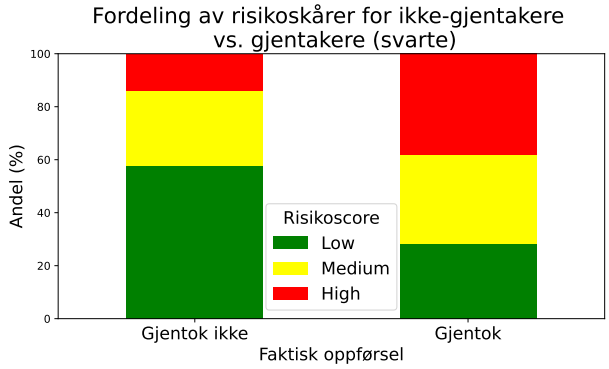

Figur 5: Sammenlikning av risikoskårer for mørke ikke-gjentakere og gjentakere. Ikke-gjentakere får mildere risikoskårer enn gjentakere, men forskjellen mellom gjentakere og ikke-gjentakere er mindre for mørke enn for hvite.

tisk regresjonsmodell med COMPAS-score som responsvariabel, kontrollert for alder, kjønn, antall tidligere lovbrudd, type lovbrudd og faktisk gjentakelse. Koeffisientene er vist i tabell 3.

Alder er den sterkeste enkeltprediktoren. Individer under 25 år fikk en koeffisient på 1,301, mens de over 45 år fikk −1,344, sammenliknet med referansegruppen 25–45 år. Antall tidligere lovbrudd (`priors_count`) har koeffisient 0,268, og faktisk gjentakelse (`two_year_recid`) har koeffisient 0,684. Partial dependence-plottet for `priors_count` (figur 6) viser at sannsynligheten for høy COMPAS-score øker jevnt med antall tidligere lovbrudd.

Etter å ha kontrollert for alle disse variablene har etnisitet fortsatt en selvstendig effekt: koeffisienten for afroamerikansk etnisitet er 0,478. Basert på modellens bias-ledd og denne koeffisienten beregnet vi at svarte tiltalte er omtrent 45% mer sannsynlige til å få høy risikoscore enn hvite med ellers identisk profil, et funn som samsvarer med Larson et al. (2016).

Gruppe	TPR	FPR	TNR	FNR	PPV
Hele	0.617	0.303	0.697	0.383	0.630
Kvinner	0.596	0.302	0.698	0.404	0.517
Menn	0.621	0.303	0.697	0.379	0.654
Hvite	0.504	0.220	0.780	0.496	0.595
Svarte	0.715	0.423	0.577	0.285	0.650

Tabell 2: Klassifiseringsrater for COMPAS per gruppe

Variabel	Koeffisient
`priors_count`	0.268
`two_year_recid`	0.684
`age_cat_Greater than 45`	-1.344
`age_cat_Less than 25`	1.301
`race_African-American`	0.478
`race_Asian`	-0.295
`race_Hispanic`	-0.423
`race_Native American`	0.842
`race_Other`	-0.806
`sex_Female`	0.218
`c_charge_degree_M`	-0.309

Tabell 3: Koeffisienter fra logistisk regresjon med COMPAS-score som responsvariabel

3.4 Random Forest

Vi trente en Random Forest-modell for å predikere faktisk gjentakelse direkte, uten etnisitet som input. Antall trær ble valgt ved å evaluere nøyaktighet for ulike antall svake lærere, og 500 trær ble valgt som optimalt. Random Forest oppnådde en nøyaktighet på 69,15% på testsettet, mot 68,58% for COMPAS, som er en marginal forbedring (tabell 4).

Modell	Nøyaktighet
COMPAS	68.58%
Random Forest	69.15%

Tabell 4: Nøyaktighet for COMPAS og Random Forest på testsettet

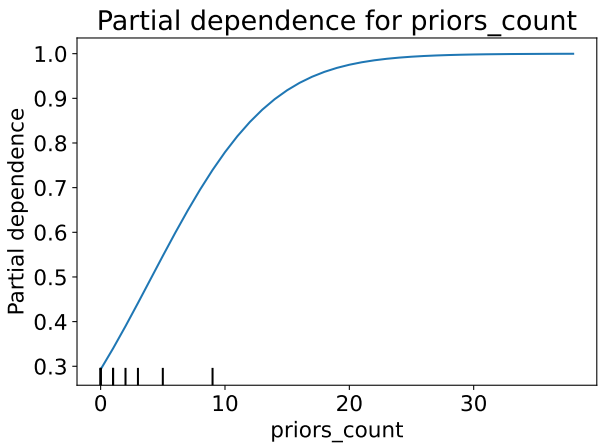

Figur 6: Partial dependence display for forklaringsvariabelen «priors_count», som måler antall tidligere lovbrudd. Høyere antall tidligere lovbrudd fører til en høyere risikoscore fra COMPAS.

Sammenlikningen av feilrater i tabell 5 viser at Random Forest har lavere FPR enn COMPAS for alle grupper , men høyere FNR mot. Modellen er altså mer tilbakeholden med å flagge høy risiko, noe som reduserer antallet falskt positive, men øker antallet falskt negative.

Gruppe	COMPAS FPR	RF FPR	COMPAS FNR	RF FNR
Hele	0.270	0.219	0.368	0.419
Hvite	0.225	0.166	0.534	0.487
Svarte	0.367	0.286	0.252	0.365

Tabell 5: Sammenligning av FPR og FNR for COMPAS og Random Forest per gruppe

Selv uten etnisitet som input er ikke modellen nøytralt fordelt mellom gruppene: forskjellen i FPR mellom svarte og hvite er 0,120 i Random Forest, mot 0,142 i COMPAS. Feature importance-analysen (figur 7) viser at `priors_count` er den klart viktigste variabelen, etterfulgt av alderskategoriene. Dette indikerer at variabler strukturelt korrelert med etnisitet kan fungere som proxy-variabler, og at modellen derfor kan gi systematisk ulike utslag for ulike grupper selv uten etnisitet som input.

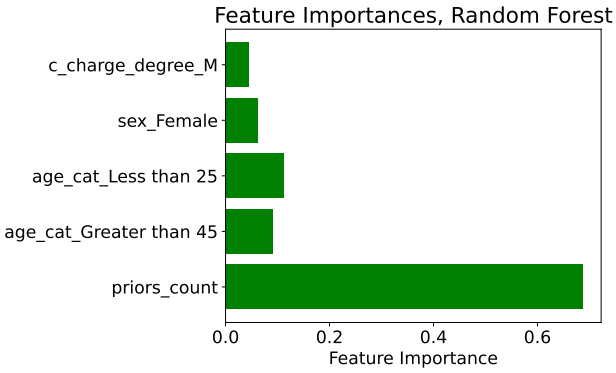

Figur 7: Feature Importance plot for Random Forest modell. Den viktigste forklaringsvariabelen virker å være antall tidligere lovbrudd.

4 Diskusjon

4.1 Sammenheng med Bayes' setning

Bayes' setning forklarer sammenhengen mellom betingede og totale sannsynligheter:

$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}.$$

For å hvordan Bayes' setning påvirker presisjonen til COMPAS, definerer vi hendelsene:

- A: En person gjentar kriminalitet innen to år
- B: COMPAS predikerer høy risiko for personen (`high_risk` $= 1$)

Dermed blir $P(A|B)$ sannsynligheten for at personen gjentar kriminalitet innen to år, gitt at COMPAS predikerer høy risiko, altså den positive prediktive verdien (PPV). $P(B|A)$ er sannsynligheten for at COMPAS predikerer høy risiko, gitt at personen gjentar kriminalitet innen to år, altså TPR. $P(A)$ er sannsynligheten for gjentakelse, altså gjentakelsesraten R_{true}, og $P(B)$ er sannsynligheten for at COMPAS predikerer høy risiko, altså den predikerte gjentakelsesraten R_{pred}. Bayes' setning kan dermed formuleres som:

$$PPV = \frac{TPR \cdot R_{true}}{R_{pred}}$$

Denne sammenhengen viser at PPV ikke bare avhenger av modellens evne til å identifisere gjentakere (TPR), men også av de faktiske

gjentakelsesratene i gruppene. Dersom R_{true} varierer mellom grupper, vil PPV også variere, selv om TPR er lik i gruppene.

4.2 Hvorfor bruke algoritmer i rettsvesenet?

4.2.1 Bakgrunn

Bruk av algoritmer i rettsvesenet er en ofte debattert sak. I Loomis v. Wisconsin argumenterte Eric Loomis for at bruken av COMPAS krenket hans rett til en rettferdig rettergang. Wisconsin Supreme Court konkluderte at verktøyet kunne brukes som beslutningsstøtte og Loomis hadde fått en rettferdig rettergang (loo (2016)). Her var det påpekt at algoritmen ikke skulle brukes alene men som en hjelpemiddel med hensyn til sine begrensninger. Algoritmer som COMPAS får mye kritikk basert på uforklarbarheten til «black-box» KI modellen. På denne måten må fordelene av bruken utveie ulempene for å kunne forsvare bruken av systemet.

4.2.2 Effektivitet

Den beste grunnen for å bruke en algoritme som COMPAS er økt effektivitet. I 2025 behandlet amerikanske føderale domstoler over 40,000 ankesaker og over 270,000 sivile saker (United States Courts, 2025). Denne høye saksmengden øker behovet for å vurdere effektivitet mot rettssikkerhet, med press på dommere og ressurser. Rettssikkerhet og rettferdig rettergang innebærer ikke bare at lover skal gjelde likt for alle, men at alle har krav på samme behandling, og dette inkluderer ventetid på behandling. Algoritmer som COMPAS kan bidra ved å raskt vurdere risiko og standardisere beslutning. Dette reduserer tiden brukt per sak og lar dommere prøve flere saker i samme tid.

4.2.3 Skjevheter

En stor kritikk av COMPAS er uforklarbarheten av algoritmen fordi det er en «black-box» modell. Men en stor fordel ved et system som COMPAS er økt likhet i behandling. I saker dømt uten algoritmer er det større sannsynlighet for at dommere bruker egne erfaringer og ubevisste skjevheter. Algoritmer anvender de samme kriteriene systematisk på alle individer og dette fører til et større grad av likebehandling. Selv om algoritmen kanskje har sin egen bias så blir denne brukt likt på alle saker, i motsetning til ulike dommere som har ulike biaser, og anvender de på ulike måter.

4.3 Hvordan kan en rettferdig algoritme se ut?

4.3.1 «Rettferdighet» som et designvalg

Er COMPAS-bruken rettferdig i praksis? For å kunne svare på dette må vi avklare hva vi mener med rettferdighet i algoritmer.

For å kunne svare på dette, er det viktig å understreke at «rettferdighet» er et designvalg, ikke et teknisk problem, når det gjelder maskinlæring-algoritmer. Det er ikke algoritmen i seg selv som er diskriminerende, men heller dataene og variablene vi mater den med, eller formålet programmet er laget for. Med andre ord er «rettferdig maskinlæring» mer et normativt og politisk valg enn et teknisk. «Rettferdighet» når det gjelder algoritmer og samfunn er ikke det samme.

4.3.2 Statistisk diskriminering

Begrepet «fair machine learning» refererer til en modell som ikke statistisk diskriminerer basert på sensitive kjennetegn, men det er ikke så enkelt som dette. Statistisk diskriminering er bruken av statistiske generaliseringer om grupper for å trekke slutninger om egenskaper eller fremtidig atferd til medlemmer av disse gruppene.

Maskinlæringsmodeller er effektive algoritmiske beslutningstakere som har tatt over, eller i det minste opererer på lik linje med, mennesker på mange måter. Dette er spesielt bekymringsfullt hvis disse modellene allerede er basert på feilaktige eller skjeve antakelser eller generaliseringer, som forverrer allerede eksisterende misoppfatninger. Derfor er det avgjørende å ta

hensyn til nøyaktighet, men også rettferdighet i disse modellene.

4.3.3 Et retrospektivt syn på rettferdighet i algoritmer

En måte å gjøre dette på er å ta hensyn til hvorfor slike ulikheter eksisterer i utgangspunktet og hvordan de ble produsert: et retrospektivt syn på rettferdighet. En rettferdig modell ville, i teorien, kunne ta hensyn til diskriminering som kan være begrunnet i legitime grunnlag. Legitimitet er definert bredt her, fordi selv om en generalisering kan være statistisk støttet, betyr det ikke nødvendigvis at den er moralsk riktig. Politiske, økonomiske, historiske og samtidige faktorer har resultert i disse uforholdsmessige utfallene.

Ifølge Kasper Lippert-Rasmussen, professor i politisk teori ved Aarhus Universitet i Danmark, «kan vi ikke ta statistiske fakta for gitt når vi rettferdiggjør politikk», fordi virkeligheten ofte er mer nyansert (Binns, 2018). Dette kan illustreres med et eksempel: Statistikk viser at svarte nabolag har mer kriminalitet enn hvite nabolag. Hvis nabolag brukes som en variabel i COMPAS, vil det øke sannsynligheten for at en mørk person får en høyere risikoscore. Dette observerte vi i tabell 1, der den predikerte gjentakelsesraten var på 57.6% for svarte, og 33.1% for hvite.

Selv om disse dataene ikke er «usanne», klarer de ikke å gi et fullstendig bilde. Det forsterker også «kriminaliseringen» av en etnisitet når dypere faktorer som sosioøkonomiske forhold er i spill. En rettferdig algoritme ville tatt hensyn til dette som en systematisk ulikhet, ikke etnisitet i seg selv. Viktige faktorer inkluderer historisk boligpolitikk, segregering, konsentrasjon av fattigdom, generasjonell underinvestering, overpolitisering og mangel på arbeid, som naturlig driver opp kriminalitet. Ideelt sett bør egenskapene som brukes til å trene en modell velges nøye med disse sårbarhetene i tankene (Binns, 2018).

4.3.4 Algoritmer mangler intensjon om å diskriminere

Et vanlig motargument som forsvarer moralsk problematiske algoritmer er deres mangel på en bevisst mental tilstand og intensjon, som er sentralt i definisjonen av diskriminering i artikkelen skrevet av Binns (Binns, 2018).

Richard Anderson svarer på dette ved å være enig i at algoritmer skiller seg fra mennesker på dette punktet, men at menneskelige skapere i høy grad kan ha slike intensjoner og bygge disse modellene med sine egne skjevheter, bevisst eller ubevisst. Resultatet vil være diskriminerende, selv om maskinen ikke er bevisst at den brukes på denne måten. Et steg i riktig retning ville være å sikre at de som skaper og programmerer disse modellene er tydelige på sine intensjoner. For eksempel, å ikke la en ekstremt innvandringskritisk programvareingeniør programmere en nasjonal modell som vurderer asylsaker. Det er viktig å sikre at de med sterke systemiske skjevheter mot en fremtredende gruppe ikke bruker denne teknologien mot allerede utsatte og sårbare befolkninger.

4.4 Å skape en rettferdig modell i et urettferdig samfunn

Den generelle enigheten blant eksperter er at det å skape en perfekt rettferdig modell i et uperfekt samfunn er vanskelig. Likevel er modeller som er «bevisste på diskriminering» bedre enn de som ikke er det.

For å forklare dette mer teknisk, bestemmer proxy-variabler en persons posisjon i et «observed room» (dataene vi ser). Måten disse variablene påvirker beslutningstaking i et «decision space» avhenger av verdiene modellen gir dem. I maskinlæring antar vi ofte at variablene som brukes i treningsdata er nøyaktige indikatorer på de reelle egenskapene vi ønsker å måle («construct space»). Dette er ofte en feilaktig tilnærming fordi vi kan ha for mye av én type data, for lite dokumentasjon av en annen type, eller mangle den historiske og samtidige forståelsen som trengs for å tolke dataene riktig. To personer kan ha nøyaktig de samme evnene, men bli representert forskjellig

i «observed space» på grunn av bias. For eksempel kan en modell anta at en kvinne er en mindre kvalifisert kandidat enn en mann fordi det finnes færre registrerte tilfeller av hennes prestasjoner på grunn av færre muligheter.

Spørsmål om rettferdighet oppstår når vi mistenker at forskjeller mellom individer i det observerbare rommet ikke nøyaktig reflekterer forskjeller i "construct space", spesielt på tvers av kjønn, rase, religion eller andre fremtredende grupper, og når disse modellene brukes til å ta beslutninger som kan skade allerede sårbare grupper. «Vi kan si at formålet med rettferdig maskinlæring er å rette oppmerksomhet mot og potensielt korrigere antakelsen om at avstander mellom mennesker i det observerbare rommet er jevnt representative for deres avstand i konstruktrommet, uavhengig av kjønn, rase, osv.», sier Binns (Binns, 2018) . Siden vi ikke direkte kan observere konstruktrommet og må stole på observerbare data, er det viktig å huske at forskjeller i observerbart rom ikke nødvendigvis tilsvarer reelle forskjeller i konstruktrommet.

Ingen modell er perfekt eller kan eliminere all ulikhet, og det burde den heller ikke, spesielt siden dataene vi bruker er basert på et urettferdig samfunn. Noen ulikheter eksisterer som et resultat av frie valg eller informert samtykke. Dette er faktorer vi kan kontrollere og dermed er forskjellene i samfunnet basert på disse rettferdige, i følge John Rawls og Robert Nozick (Binns, 2018). Andre faktorer som rase, kjønn, orientering og helsetilstand er kjennetegn man ikke velger. Derfor er det nødvendig å ha høyere standarder for modeller slik at disse egenskapene (kodet som variabler) ikke brukes som en direkte eller indirekte ulempe. Vi må strebe etter å gjøre modeller så rettferdige som mulig.

4.4.1 Like muligheter vs. like utfall

Det er også viktig å ha i bakhodet ulike mål på likhet når man vurderer og lager disse modellene. Det finnes ikke én enkelt definisjon av rettferdighet som passer perfekt for alle algoritmer. Noen modeller vil bli ansett som mer rettferdige hvis de er programmert til å prioritere likhet i muligheter, mens andre vil være mer rettferdige hvis de prioriterer likhet i resultater, avhengig av hva modellen brukes til.

For eksempel, hvis en modell brukes innen økonomisk rettferdighet, som en ansettelsesalgoritme, er det rettferdig å sikre at alle med de samme evnene har lik sjanse til å bli kalt inn. I tilfeller i sivile rettssystemer bør en modell som COMPAS fokusere mer på likhet i resultater, og sikre at prediksjonsfeil, spesielt skadelige som falske positive, er likt fordelt mellom grupper slik at ingen gruppe uforholdsmessig utsettes for urettferdige utfall. Dette var en gyldig kritikk av COMPAS-systemet. Selv om rase ikke ble gitt som en direkte input, brukte algoritmen andre faktorer som utdanning, arbeid og miljø som proxies for rase, og det fungerte. Svarte tiltalte hadde betydelig høyere sannsynlighet for å få høyere risikoscore sammenlignet med hvite tiltalte, som vi så i figur 1 og tabell 2. Dette så vi også i RF modellen, selv om etnisitet ble ekskludert fra forklaringsvariablene (tabell 5).

4.5 Tiltak for å korrigere urettferdige modeller

Gal Yona, en forsker ved Google, tilbyr to enkle tiltak for å forbedre disse modellene. En måte er å trene dem på nye data i tilfeller der samfunnet beveger seg i en bedre retning. For eksempel var det mest populære bildet assosiert med ordet «kvinne» i 2007 et seksualisert bilde, mens det i 2017 var et bilde av en kvinne som går tur i Rocky Mountains. I noen tilfeller, etter hvert som samfunnet utvikler seg, får vi mer representative og rettferdige data til å trene modeller. Den andre strategien er å bruke menneskelig kontroll for å vurdere modellens resultater. Menneskelig evaluering forbedrer kvaliteten og kan bidra til å forhindre fremtidige tilfeller av diskriminering, spesielt i subtile tilfeller hvor bias ikke er åpenbar for algoritmen (Yona, 2017).

4.5.1 «Unware»-tilnærming

En annen måte å skape mer rettferdige modeller på er å begrense tilgang til sensitiv informasjon som kan brukes til å diskriminere. Dette kalles «unaware»-tilnærmingen. For eksempel å ikke gi en ansettelsesmodell tilgang til kjønn.

Dette er imidlertid ikke effektivt på lang sikt, fordi modeller kan utlede slike egenskaper gjennom korrelerte variabler, som fysisk styrke eller lengden på militærtjeneste. Derfor kan det å holde tilbake informasjon gjøre mer skade enn nytte for minoritetsgrupper (Yona, 2017).

4.5.2 «Aware»-tilnærming

Et mer lovende alternativ er «aware»-tilnærmingen, som kan være mer rettferdig fordi den gir tilgang til sensitive klassifikasjoner. I stedet for kun å fokusere på rettferdighet i prosessen, sikter den mot rettferdighet i resultatene. Modellen får tilgang til sensitive egenskaper for å korrigere strukturelle skjevheter.

Selv om dette kan virke urettferdig ved første øyekast, kan det føre til bedre resultater ved å adressere eksisterende urettferdigheter. En rettferdig modell vil ha som mål å ha like feilrater på tvers av alle grupper, noe som ikke var tilfellet i COMPAS-modellen (tabell 2. Den klassifiserte feilaktig afroamerikanere som høy risiko for tilbakefall, samtidig som den feilaktig klassifiserte hvite som lav risiko.

For å oppnå dette må modellen imidlertid gjenkjenne gruppetilhørighet og justere seg når den oppdager ulike feilrater. En bedre modell kan for eksempel være mildere overfor svarte og strengere overfor hvite. Dette bidrar til å fordele skade mer likt, men kan redusere den totale nøyaktigheten.

4.6 Northpointe vs. ProPublica

Bruken av risikovurderingsverktøy som COMPAS har vært gjenstanden for mye debatt, særlig etter at ProPublica publiserte sin studie. I sitt tilsvar avviser Northpointe påstanden om at COMPAS diskriminerer afroamerikanere, og begrunner dette ved hjelp av en bestemt forståelse av algoritmisk rettferdighet. De hevder at modellen er rettferdig fordi den er kalibrert på tvers av forskjellige grupper, hvor personer med samme risikoscore har tilnærmet lik sannsynlighet for tilbakefall, uavhengig av rase. Med andre ord mener Northpointe at dersom algoritmen gir like presise prediksjoner for ulike grupper, kan den ikke anses som diskriminerende mer enn det som er statistisk sannsynlig. De viser også til at forskjeller i utfall i stor grad kan forklares av ulike grunnrater for tilbakefall mellom grupper, og ikke nødvendigvis av skjevheter i selve modellen. Denne sammenhengen ble også diskutert i kapittel 4.1.

ProPublica utfordrer imidlertid denne forståelsen ved å rette oppmerksomheten mot hvordan feilene i algoritmen fordeles. Deres analyse viser at afroamerikanske tiltalte oftere blir feilaktig klassifisert som høy risiko, mens hvite tiltalte oftere blir feilaktig klassifisert som lav risiko. Dette så vi også i tabell 2 i vår analyse. Dette innebærer at konsekvensene av feil ikke er jevnt fordelt, noe som kan få alvorlige utslag i praksis. For eksempel kan det bli strengere straffeutmåling eller større sannsynlighet for varetektsfengsling. ProPublica argumenterer derfor for at selv om modellen kan være statistisk presis på et overordnet nivå, kan den likevel produsere systematiske skjevheter som rammer enkelte grupper uforholdsmessig hardt. De legger dermed til grunn en annen forståelse av rettferdighet, hvor lik fordeling av feil er sentralt.

Kjernen i uenigheten mellom Northpointe og ProPublica ligger i hvilke kriterier som skal brukes for å vurdere om en algoritme er rettferdig. Northpointe fokuserer på prediktiv likhet, altså at modellen er like treffsikker for alle grupper, mens ProPublica legger vekt på konsekvensene av feil og hvordan disse fordeles. Disse to perspektivene lar seg i praksis vanskelig forene, særlig når grunnratene for tilbakefall varierer mellom grupper. Uenigheten er derfor ikke bare empirisk, men også normativ: den handler om hvilke rettferdighetsprinsipper som bør prioriteres i rettsvesenet. Dette illustrerer en grunnleggende utfordring ved bruk av

algoritmer som COMPAS, hvor teknisk nøyaktighet ikke nødvendigvis går hånd i hånd med opplevd eller normativ rettferdighet.

5 Konklusjon

Rettssikkerhet er et av de mest grunnleggende prinsippene i en rettstat som Norge. Når nye hjelpemidler introduseres i retten, må det vurderes om dette truer rettferdig rettergang. Den største utfordringen med KI-algoritmer er mangelen på forståelse av hvordan de fungerer. Analyser som ProPublica sin kan vise potensielle skjevheter og statistisk diskriminering i algoritmen.

Vår analyse bekrefter skjevhetene ProPublica identifiserte. COMPAS har en falsk positivrate på 0.423 for svarte mot 0.220 for hvite, og svarte tiltalte er omtrent 45% mer sannsynlige til å få høy risikoscore selv etter kontroll for alder, kjønn og kriminell historikk. At vår Random Forest-modell reproduserte lignende gruppeforskjeller uten etnisitet som input viser at problemet ikke løses ved å fjerne etnisitet fra dataene, på grunn av proxy-variabler.

Når man bruker «black-box»-algoritmer så er rettferdighet noe som må bli lært, ikke noe som oppstår av seg selv. En algoritme velger å predikere feil oftere mot en etnisitet dersom det gir høyere treffsikkerhet. Disse prioriteringene er noe man må lære maskinen, og da må brukeren velge hva som er viktigere: høyere treffsikkerhet eller mindre diskriminering? Dersom man velger å påvirke hvordan en modell bruker data direkte, ved å for eksempel endre vekter eller endre datagrunnlaget, gjør man et aktivt valg som påvirker resultatet. Dermed introduserer man sin egen bias, noe som fører til en form for «positiv diskriminering».

Dataen brukt i COMPAS er en refleksjon av diskriminering som allerede eksisterer i verden. Dommere som bruker COMPAS scores er gitt en advarsel om å ta hensyn til algoritmen sine begrensninger. Med dette hensynet kan bruk av COMPAS være et effektivt hjelpemiddel. Likevel mener vi at man ikke kan si at COMPAS er en rettferdig algoritme.

Referanser

State v. loomis. Wisconsin Supreme Court, 881 N.W.2d 749, 2016. URL https://law.justia.com/cases/wisconsin/supreme-court/2016/2015ap000157-cr.html. Accessed: 2026-04-16.

Reuben Binns. What can political philosophy teach us about algorithmic fairness? *IEEE Security Privacy*, 16(3):73–80, 2018. doi: 10.1109/MSP.2018.2701147.

Jeff Larson, Surya Mattu, Lauren Kirchner, and Julia Angwin. How we analyzed the COMPAS recidivism algorithm. ProPublica, may 2016. URL https://www.propublica.org/article/how-we-analyzed-the-compas-recidivism-algorit Accessed: 2026-04-10.

ProPublica. compas-scores-two-years.csv. https://github.com/propublica/compas-analysis/blob/master/compas-scores-two-years.csv, 2016. Hentet: 14. april 2026.

United States Courts. Federal judicial caseload statistics 2025. United States Courts, 2025. URL https://www.uscourts.gov/data-news/reports/statistical-reports/federal-judicial-caseload-statistics/judicial-caseload-indicators-federal-judicial Accessed: 2026-04-16.

Gal Yona. A gentle introduction to the discussion on algorithmic fairness. Towards Data Science, 2017. URL https://medium.com/data-science/a-gentle-introduction-to-the-discussion-on-al Accessed: 2026-04-15.